


1. Regla Empírica

Es una guía que indica la proporción aproximada de datos que caen dentro de determinado número de desviaciones estándar respecto a la media.

- **Condición de aplicación:** Se utiliza cuando la distribución de los datos en un histograma o gráfico es **aproximadamente simétrica** o en forma de campana.
- **Porcentajes clave:**
 - ~**68%** de las observaciones se encuentran a una desviación estándar de la media ($\bar{x} \pm 1S$).
 - ~**95%** de las observaciones se ubican a dos desviaciones estándar de la media ($\bar{x} \pm 2S$).
 - ~**99.7%** (prácticamente todas las observaciones) caen dentro de tres desviaciones estándar de la media ($\bar{x} \pm 3S$).

3 ¿Cómo leer la Desviación Estándar? La campana 🔔 (Regla empírica)

Si tus datos son simétricos (forma de campana 🔔) con media $\bar{x}$ y desviación S :



2. Teorema o Regla de Chebyshev

Es un principio estadístico más general que establece un límite mínimo garantizado de observaciones contenidas alrededor de la media.

- **Condición de aplicación:** Se aplica a **cualquier conjunto de datos, sin importar la forma de la distribución** (incluso si la distribución es sesgada o asimétrica)89.
- **Regla principal:** Establece que **al menos 3/4 partes (el 75%)** de las observaciones estarán contenidas dentro de dos desviaciones estándar alrededor de la media ($\bar{x} \pm 2S$).

3. Diagrama de Caja (Boxplot)

Es una técnica gráfica descriptiva que permite visualizar de manera rápida la variabilidad, la simetría y las características principales de una variable, así como comparar varios conjuntos de datos simultáneamente.

- **Los 5 números básicos:** Su construcción se apoya en el resumen de cinco medidas de posición:
 - **Valor Mínimo**
 - **Primer Cuartil (C_1 o Q_1):** Acumula el 25% de los datos.
 - **Mediana (C_2 o Q_2):** Punto central que divide la distribución al 50%.
 - **Tercer Cuartil (C_3 o Q_3):** Acumula el 75% de los datos.
 - **Valor Máximo**
- **Estructura del gráfico:**
 - **Caja central:** Se dibuja un rectángulo cuyos extremos van de C_1 a C_3 , marcando la mediana con una línea vertical dentro de la caja.
 - La longitud de la caja es el **Rango Intercuartil** ($RIC = C_3 - C_1$).
 - **Bigotes:** Son líneas que se extienden a los lados hasta límites calculados como $L_1 = C_1 - 1.5(RIC)$ a la izquierda y $L_2 = C_3 + 1.5(RIC)$ a la derecha.
 - **Datos Anómalos (Outliers):** Cualquier valor que se ubique más allá de las líneas límite se marca con un asterisco o símbolo separado, identificándolo explícitamente como una observación atípica

Explicación:

Para entender mejor cómo interactúan la **Regla Empírica**, el **Teorema de Chebyshev** y el **Diagrama de Caja**, trabajaremos con un ejemplo numérico concreto paso a paso.

Paso 1: El conjunto de datos

Supongamos que un administrador mide el tiempo de atención en minutos para una muestra de $n = 10$ clientes en una sucursal:

Datos ordenados(minutos): 10, 12, 14, 15, 16, 18, 20, 22, 24, 29

Paso 2: Cálculo de la Media ($\bar{x}$) y la Desviación Estándar (S)

1. Media muestral ($\bar{x}$):34

$$2. \bar{x} = \frac{\sum x_i}{n} = \frac{10+12+14+15+16+18+20+22+24+29}{10} = \frac{180}{10} = 18 \text{ minutos}$$

3.

4. Varianza muestral (S^2) y Desviación Estándar (S):25

- Suma de desviaciones al cuadrado: $(10-18)^2 + (12-18)^2 + \dots + (29-18)^2 = 306$
 - Varianza: $S^2 = \frac{306}{10-1} = \frac{306}{9} = 34$
 - Desviación estándar: $S = \sqrt{34} \approx 5.83 \text{ minutos}$
-

Paso 3: Aplicación de la Regla Empírica y Teorema de Chebyshev

A. Regla Empírica (Aplica si la distribución es aproximadamente simétrica)

- Intervalo a 1 desviación estándar ($\bar{x} \pm 1S$):6**
 - $18 \pm 5.83 = (12.17, 23.83)$
 - Verificación en los datos:* Los valores que caen dentro de este rango son $\{14, 15, 16, 18, 20, 22\}$ (6 de 10 datos = **60%**, muy cercano al ~68% estimado).
- Intervalo a 2 desviaciones estándar ($\bar{x} \pm 2S$):**
 - $18 \pm 2(5.83) = 18 \pm 11.66 = (6.34, 29.66)$
 - Verificación en los datos:* Todos los valores (10 a 29) caen dentro del intervalo (10 de 10 datos = **100%**, la regla predice ~95%).

B. Teorema de Chebyshev (Aplica a cualquier tipo de distribución)

- Para $k = 2$ desviaciones estándar, el teorema garantiza que **al menos el 75%** ($1 - 1/2^2 = 3/4$) de las observaciones estarán contenidas entre 6.34 y 29.66 minutos.
 - En nuestro conjunto real, el **100%** de los datos se encuentra en ese intervalo, cumpliendo la garantía mínima del 75%.
-

Paso 4: Construcción del Diagrama de Caja (Resumen de 5 números)

Para elaborar la gráfica de caja requerimos las cinco medidas de posición:

1. **Valor Mínimo:** 10
2. **Primer Cuartil (C_1 o Q_1):** Mediana de la mitad inferior {10, 12, 14, 15, 16} $\rightarrow C_1 = 14$.
3. **Mediana (C_2 o $\tilde{m}$):** Promedio de los dos datos centrales $\frac{16+18}{2} \rightarrow \tilde{m} = 17$.
4. **Tercer Cuartil (C_3 o Q_3):** Mediana de la mitad superior {18, 20, 22, 24, 29} $\rightarrow C_3 = 22$.
5. **Valor Máximo:** 29

Cálculo del Rango Intercuartil (RIC) y Límites de Atípicos:

- **Rango Intercuartil:** 12
 - $RIC = C_3 - C_1 = 22 - 14 = 8 \text{ minutos}$
-
- **Límite inferior para la línea o bigote (L_1):**
 - $L_1 = C_1 - 1.5(RIC) = 14 - 1.5(8) = 14 - 12 = 2$
-
- **Límite superior para la línea o bigote (L_2):**
 - $L_2 = C_3 + 1.5(RIC) = 22 + 1.5(8) = 22 + 12 = 34$
-

Estructura final del gráfico:

- **La Caja:** Se dibuja desde $C_1 = 14$ hasta $C_3 = 22$, marcando una línea vertical interna en la mediana $\tilde{m} = 17$.
- **Los Bigotes:** La línea izquierda se extiende hasta el valor mínimo real (10) y la derecha hasta el máximo real (29).
- **Datos Anómalos (Outliers):** Como ningún dato es menor que 2 ni mayor que 34, **no existen observaciones atípicas** en esta muestra

Ejemplo 2 con valores atípicos:

Tomando la misma variable de tiempo de atención (en minutos) para una muestra de $n = 10$ clientes, introduciremos una observación atípica. Supongamos que un problema en el sistema causó que un cliente esperara **50 minutos**, mientras que los demás mantuvieron tiempos habituales:

Datos ordenados(minutos): 10, 12, 14, 15, 16, 18, 20, 22, 24, 50

Paso 1: Efecto del dato atípico en la Media vs. Mediana

- **Mediana ($\tilde{m}$):** Es el promedio de los valores centrales 5 y 6:
 - $\tilde{m} = \frac{16+18}{2} = 17 \text{ minutos}$
 - *La mediana se mantiene idéntica al ejemplo anterior (17 min) porque no se deja afectar por valores extremos.*
 - **Media ($\bar{x}$):**
 - $\bar{x} = \frac{10+12+14+15+16+18+20+22+24+50}{10} = \frac{201}{10} = 20.1 \text{ minutos}$
 - *La media subió de 18 a 20.1 minutos debido a que es altamente sensible a valores extremos.*
-

Paso 2: Obtención de los 5 números básicos

1. **Mínimo:** 10
 2. **Primer Cuartil (C_1):** Mediana de la mitad inferior {10, 12, 14, 15, 16} $\rightarrow C_1 = 14$
 3. **Mediana (C_2):** $\tilde{m} = 17$
 4. **Tercer Cuartil (C_3):** Mediana de la mitad superior {18, 20, 22, 24, 50} $\rightarrow C_3 = 22$
 5. **Máximo:** 50
-

Paso 3: Cálculo del Rango Intercuartil (RIC) y Límites

- **Rango Intercuartil:**
 - $RIC = C_3 - C_1 = 22 - 14 = 8 \text{ minutos}$
- **Límite inferior para la línea (L_1):**
 - $L_1 = C_1 - 1.5(RIC) = 14 - 1.5(8) = 2$
- **Límite superior para la línea (L_2):**
 - $L_2 = C_3 + 1.5(RIC) = 22 + 1.5(8) = 34$

Paso 4: Identificación del Dato Atípico (Outlier)

Comparamos las observaciones con los límites calculados:

- Ningún valor es menor a $L_1 = 2$.
- El valor 50 sobrepasa el límite superior de $L_2 = 34$ ($50 > 34$).

Por lo tanto, **el valor 50 se clasifica formalmente como un dato anómalo o atípico (outlier)**.

Paso 5: Cómo cambia el dibujo del Diagrama de Caja

1. **La Caja:** Se construye exactamente igual, desde $C_1 = 14$ hasta $C_3 = 22$, marcando la mediana en 17.
2. **Bigote Izquierdo:** Se extiende desde $C_1 = 14$ hacia la izquierda hasta el valor mínimo real (10).
3. **Bigote Derecho (Regla clave con atípicos): No se extiende hasta 50.** La línea del bigote solo se traza hasta el **último valor no atípico dentro del límite** $L_2 = 34$, que en este caso es 24.
4. **Marcación del Atípico:** La observación de 50 se grafica como un punto aislado o asterisco (*) separado a la derecha de la gráfica.

